

OPTIMASI RUTE PENGIRIMAN BARANG PADA TAHAP *LAST MILE* DENGAN SISTEM *TRUCK-DRONE* MENGGUNAKAN METODE *MEAN SHIFT CLUSTERING* DAN ALGORITMA GENETIKA

Ervita Indah Pratiwi¹, Yudi Satria², Dhian Widya³

1. Departemen Matematika, Fakultas Matematika dan Ilmu Pengetahuan Alam, Universitas Indonesia, Depok 16424, Indonesia
2. Departemen Matematika, Fakultas Matematika dan Ilmu Pengetahuan Alam, Universitas Indonesia, Depok 16424, Indonesia
3. Departemen Matematika, Fakultas Matematika dan Ilmu Pengetahuan Alam, Universitas Indonesia, Depok 16424, Indonesia

Abstrak

Pengiriman barang dari depot terakhir menuju ke lokasi pelanggan adalah pengiriman *last mile*. Pengiriman *last mile* sering dianggap sebagai tahap yang paling mahal dan kurang efisien. Beberapa permasalahan yang dihadapi dalam pengiriman *last mile* adalah biaya yang tinggi, waktu pengiriman yang lama, dan kemungkinan barang rusak. Penggunaan sistem kendaraan *truck-drone* dalam pengiriman *last mile* dapat dijadikan sebagai solusi untuk mengatasi permasalahan dalam *last mile*. Tujuan dari penelitian ini adalah menemukan rute pengiriman barang yang meminimalkan biaya pengiriman dengan menggunakan sistem *truck-drone* dalam *last mile*. Pendekatan yang diusulkan untuk mencari rute optimal terdiri dari dua fase yaitu fase *clustering* dan *routing*. Dalam fase *clustering* menggunakan *mean shift clustering* untuk mengelompokkan lokasi pelanggan dan mencari lokasi parkir (pusat *cluster*). Dalam fase *routing* menggunakan algoritma genetika untuk menemukan rute optimal. Implementasi pada 90 pelanggan didapatkan penggunaan metode *mean shift clustering* diikuti oleh algoritma genetika, dapat menghasilkan rute optimal yang meminimalkan total biaya. Hal ini ditunjukkan dari penurunan biaya pada rute *mean shift clustering* mencapai 3.51% dibandingkan *clustering* dengan metode *intuitif*. Selain itu, analisis hasil juga mencerminkan bahwa penerapan *mean shift clustering* mampu mengurangi total jarak sebesar 27.93 % dan waktu tempuh sebesar 25.83 %

Kata kunci: Algoritma genetika, *Last mile delivery*, *Mean Shift Clustering*, Sistem *truck drone*

Abstract

The delivery process from the last depot to the customer's location is known as last-mile delivery. Last-mile delivery is often considered the most expensive and less efficient stage. Some challenges in last-mile delivery include high costs, long delivery times, and the possibility of damaged goods. The use of a *truck-drone* system in last-mile delivery can be a solution to address these challenges. The objective of this research is to find delivery routes that minimize delivery costs using a *truck-drone* system in the last mile. The proposed approach to finding optimal routes consists of two phases: clustering and routing. In the clustering phase, mean shift clustering is used to group customer locations and identify parking locations (cluster centers). In the routing phase, a genetic algorithm is employed to find the optimal routes. The implementation on 90 customers showed that the use of mean shift clustering followed by a genetic algorithm could generate optimal routes that minimize the total cost. This is evident from the cost reduction in mean shift clustering routes by 3.51% compared to the initial clustering solution with intuitif method. Furthermore, the results analysis also reflects that the implementation of Mean Shift Clustering can reduce the total distance by 27.93% and travel time by 25.83%.

Keywords: Genetic algorithm, Last-mile delivery, Mean Shift Clustering, *Truck-drone* system

Pendahuluan

Pada era digital ini, internet bukan hanya menjadi sarana komunikasi, tetapi juga menjadi pondasi untuk berbagai aktivitas, termasuk kegiatan ekonomi. Menurut data dari Kementerian Komunikasi dan Informatika (Kominfo) pada Januari 2023, penggunaan internet aktif mencapai 212,9 juta orang atau 77% dari populasi Indonesia (Kominfo, 2023). Dengan jumlah pengguna internet yang mencapai sebesar ini, menciptakan dampak signifikan terhadap kebutuhan masyarakat dalam berbagai layanan secara *virtual*, khususnya aktivitas jual-beli melalui platform *e-commerce*.

Pertumbuhan *e-commerce* di Indonesia mengalami peningkatan yang signifikan, mencapai 12,79% dari tahun sebelumnya pada tahun 2022 (Statista, 2022). Proyeksi dari Bain & Company (2022) menyebutkan kontribusi sektor *e-commerce* di Indonesia dapat mencapai US\$ 130 miliar pada tahun 2025. Dengan meningkatnya transaksi online, permintaan akan pengiriman barang juga semakin meningkat, khususnya dalam layanan *last mile delivery*.

Last mile delivery, sebagai tahap akhir dalam proses pengiriman, seringkali dianggap sebagai tahap yang paling mahal, mencapai 53% dari total biaya pengiriman barang (Dolan, 2021). Beberapa permasalahan yang dihadapi dalam *last mile delivery* antara lain jarak yang kompleks, kemacetan lalu lintas di perkotaan, dan lokasi yang sulit dijangkau (Eskandaripour et al., 2023). Dalam konteks ini, pengoptimalan rute pengiriman menjadi kunci utama dalam meningkatkan efisiensi logistik.

Seiring dengan perkembangan zaman, penggunaan *Unmanned Aerial Vehicles* (UAV) atau *drone* untuk *last mile delivery* menjadi solusi inovatif. Konsep pengiriman menggunakan *drone* pertama kali diperkenalkan oleh amazon pada tahun 2013 dengan nama "*Prime Air*". Meskipun *drone* memiliki keunggulan dalam mengurangi waktu pengiriman dan konsumsi bahan bakar, tetapi juga memiliki keterbatasan, seperti jangkauan penerbangan terbatas dan kapasitas muatan kecil.

Sebagai alternatif untuk mengatasi keterbatasan *drone*, konsep sistem *truck-drone* digunakan. Sistem ini menggabungkan kendaraan *truck* dan *drone* dalam pengiriman, memanfaatkan keunggulan masing-masing kendaraan. *Truck*, dengan kapasitas angkut yang besar, efisien untuk volume pengiriman besar, sementara *drone* dapat menangani pengiriman dalam jarak dekat dan area sulit dijangkau. Namun, mengelola sistem *truck-drone* memerlukan perencanaan rute dan penjadwalan yang efisien.

Masalah *routing* dan penjadwalan dalam sistem *truck-drone* pertama kali diperkenalkan oleh Muray dan Chu (2015), mengusulkan model *Flying Sidekick Traveling Salesman Problem* (FSTSP). Pendekatan ini menggunakan metode heuristik untuk mengatasi masalah. Penelitian lebih lanjut kemudian dikembangkan model FSTSP, yaitu beberapa *drone* bekerja dengan satu *truck* oleh Ferrandez et al. (2016), dan modelnya disebut *multiple Flying Sidekick Traveling Salesman Problem* (mFSTSP). Penyelesaian masalah menggunakan algoritma *k-means* dan algoritma genetika.

Dalam konteks pengiriman sistem *truck-drone*, permasalahan yang dihadapi termasuk dalam kelas masalah *NP-hard*, yaitu solusi optimal sulit ditemukan dalam waktu yang efisien. Oleh karena itu, diperlukan pendekatan optimisasi yang canggih, seperti algoritma genetika. Algoritma ini memiliki keunggulan dalam menangani ruang pencarian yang besar dan menghindari solusi optimum lokal karena menggunakan pendekatan probabilitas dan mengintegrasikan konsep seleksi alam, rekombinansi, dan mutasi (Savuran dan Karakaya, 2016).

Arishi et al. (2022) memperkenalkan variasi model masalah pengiriman sistem *truck-drone* terbaru, yaitu *Parking Location Traveling Salesman Problem with Homogeneous Drones* (PLTSPHD). Model ini mempertimbangkan lokasi parkir untuk *drone*, meminimalkan total biaya operasional pengiriman. Pada penelitian Arishi et al. (2022) lokasi parkir ditentukan menggunakan *k-means clustering* dengan batasan terkait *drone*. Hasil *clustering* menggunakan *k-means* pada paper tersebut memberikan kontribusi dalam meningkatkan efisiensi dan efektivitas dalam penyelesaian permasalahan rute pengiriman menggunakan *truck drone*.

Pada penelitian ini, mengadaptasi model masalah PLTSPHD dan penyelesaian menggunakan metode *mean shift clustering* untuk menemukan lokasi parkir dan algoritma genetika untuk menentukan rute optimal. Dibandingkan dengan *k-means*, *mean shift clustering* memiliki keunggulan karena tidak memerlukan jumlah *cluster* yang telah ditentukan sebelumnya. Algoritma ini dapat secara otomatis menentukan pusat *cluster* berdasarkan distribusi data, sehingga lebih cocok untuk situasi di mana jumlah *cluster* tidak diketahui sebelumnya atau dapat berubah seiring waktu (Abdulkarim dan Alshammar, 2015).

Traveling Salesman Problem

Traveling Salesman Problem (TSP) adalah masalah kombinatorial klasik. TSP pertama kali diperkenalkan oleh Dantzig dkk (1954) untuk memecahkan contoh masalah praktis. Konsep TSP dapat diilustrasikan sebagai seorang salesman yang mengunjungi kota-

kota, dengan setiap kota hanya dikunjungi satu kali dan kembali ke kota awal. Tujuan TSP adalah menemukan lintasan terpendek yang mengunjungi setiap kota tepat satu kali, meminimalkan total jarak tempuh. Berikut model matematis TSP berdasarkan Hamdy, (1996).

$$\min \sum_{i=1}^n \sum_{j=1}^n c_{ij} x_{ij} \quad (1)$$

Kendala-kendala TSP

$$\sum_{j=1}^n x_{ij} = 1 \quad i = (1, 2, \dots, n) \quad (2)$$

$$\sum_{i=1}^n x_{ij} = 1 \quad j = (1, 2, \dots, n) \quad (3)$$

$$x_{ij} = (0,1) \quad (4)$$

Persamaan (1) digunakan sebagai fungsi objektif yang umumnya digunakan pada masalah TSP. Fungsi ini mencari solusi optimal dengan melihat jalur terpilih sehingga total rutenya memiliki jarak terpendek. Persamaan (2) dan persamaan (3) memastikan jalur-jalur yang dilewati pada suatu rute hanya dilakukan satu kali. Persamaan (4) merupakan variabel keputusan.

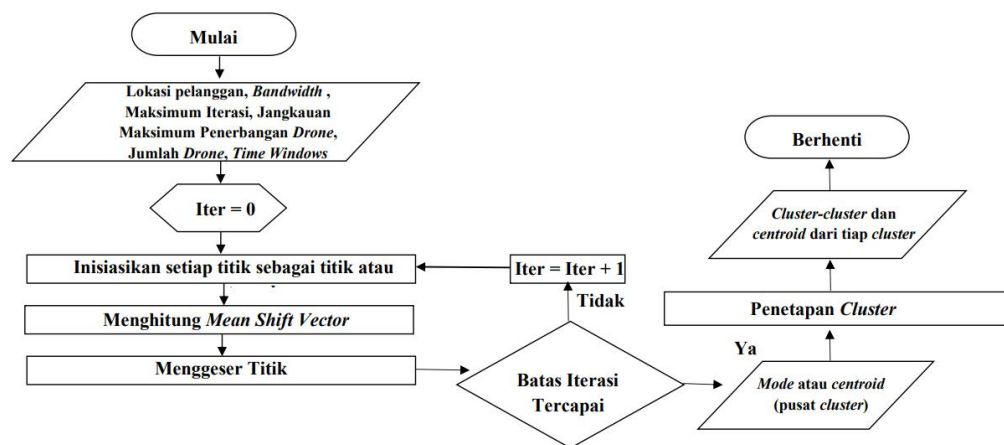
Mean Shift Clustering

Clustering merupakan proses pengelompokan objek-objek data ke dalam kelompok-kelompok yang saling berhubungan berdasarkan kesamaan karakteristik atau atribut. Kelompok-kelompok tersebut disebut *cluster*. Tujuan dari *clustering* adalah untuk memaksimalkan variansi antar *cluster* yang berbeda dan meminimalkan variansi antara objek-objek dalam *cluster* yang sama (Tan et al., 2006).

Mean shift clustering merupakan algoritma pengelompokan berbasis kepadatan (*density-based clustering*) non-parametrik yang secara iteratif mengelompokkan titik-titik observasi ke dalam kelompok dengan menggeser titik tersebut ke *mode* (*mode* adalah kepadatan tertinggi atau pusat kerapatan dalam suatu wilayah), sehingga dikenal juga sebagai algoritma *seeking mode*. Ide dasar algoritma *mean shift* adalah pada setiap iterasi, titik observasi digeser menuju ke pusat kerapatan yang berada dalam satu wilayah. Dengan

cara ini, titik-titik observasi akan saling menarik satu sama lain dan berkumpul menjadi *cluster-cluster* (Carreira, 2015).

Dalam prosesnya *mean shift clustering* tidak memerlukan jumlah *cluster* di awal. Sebagai gantinya, *mean shift clustering* sangat bergantung pada parameter *bandwidth*. *Bandwidth* adalah parameter yang mengontrol jangkauan pengaruh perpindahan pusat *cluster* (Carreira, 2015). *Bandwidth* yang kecil dapat menghasilkan *cluster* yang berlebihan, sementara nilai yang tinggi dapat dengan keliru menggabungkan beberapa *cluster*.



Gambar 1 Flowchart Mean Shift Clustering

Prosedur *mean shift clustering* untuk menyelesaikan masalah pada penelitian ini sama dengan prosedur pada *mean shift clustering* umumnya, yang membedakan hanya penambahan batasan untuk setiap *cluster*. Batasan yang digunakan dalam *mean shift clustering*, sebagai berikut:

- Dalam satu *cluster* jumlah pelanggan tidak melebihi jumlah *drone* yang tersedia.
- Radius pelanggan yang dilayani dalam satu *cluster* tidak boleh melebihi jarak maksimum penerbangan *drone*.

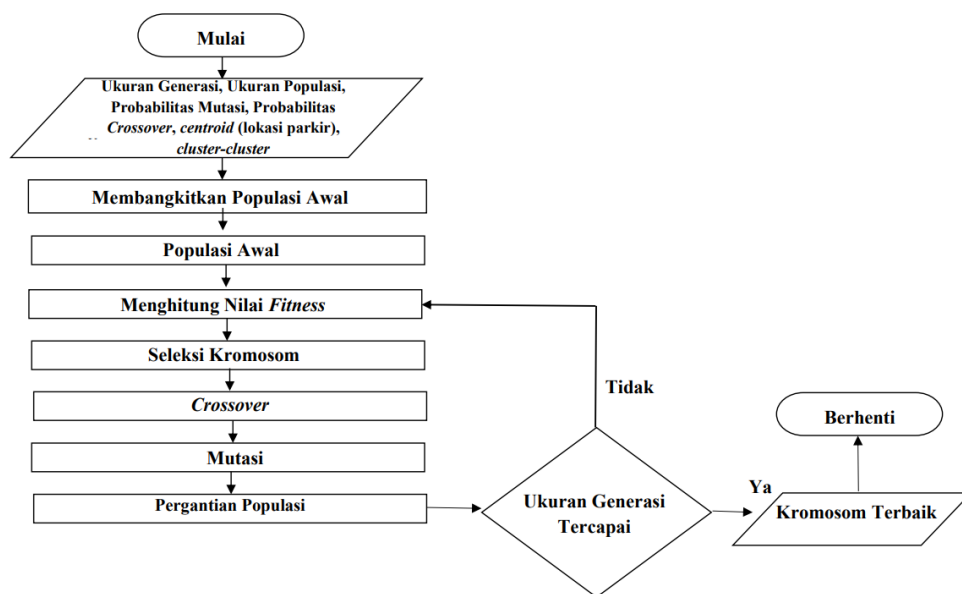
Algoritma Genetika

Algoritma Genetika (AG) merupakan pendekatan optimasi yang mengambil inspirasi dari prinsip-prinsip evolusi dalam genetika organisme hidup. Ditemukan pertama kali oleh John Holland pada tahun 1975, AG meniru konsep seleksi alam, *crossover*, dan mutasi untuk mencari solusi optimal dari berbagai permasalahan. AG bertujuan untuk memperbaiki populasi solusi melalui iterasi berulang, dengan harapan mencapai solusi yang lebih baik dari waktu ke waktu.

Dalam konteks AG, representasi kromosom memainkan peran penting. Permasalahan

optimasi diartikan sebagai mencari solusi terbaik dari ruang pencarian, dan representasi tersebut dapat berupa biner, bilangan real, atau permutasi, tergantung pada sifat permasalahan yang dihadapi. Penggunaan operator-genetik seperti *crossover* dan mutasi membantu menghasilkan variasi dalam populasi, menghindarkan AG dari terjebak dalam solusi lokal yang sub-optimal.

Algoritma Genetika telah sukses diterapkan dalam berbagai bidang, termasuk optimasi rute pada *Traveling Salesman Problem* (TSP). Keunggulannya terletak pada kemampuannya menangani permasalahan dengan ruang pencarian yang kompleks dan besar.



Gambar 2 Flowchart Algoritma Genetika

Pada penelitian ini, proses *crossover* menggunakan metode *order crossover* (OX), yaitu dua kromosom terpilih secara acak, dan *subsequences* ditukar untuk menghasilkan keturunan baru. Mutasi, yang terjadi dengan probabilitas tertentu, menggunakan *reversing mutation* yang membalik urutan gen di antara dua posisi gen yang dipilih secara acak. Sementara itu, pembangkitan populasi awal dilakukan dengan metode *All Nearest Neighbors* (ANN), yang mengatur aturan khusus untuk membentuk populasi awal.

Model Matematis PLTSPHD untuk pengiriman barang pada tahap *last mile*

Rancangan yang diusulkan dalam skripsi ini bertujuan untuk menciptakan rute pengiriman barang yang optimal dari depot ke setiap lokasi pelanggan, dengan tujuan mengurangi total biaya pengiriman. Untuk implementasinya, digunakan sistem *truck-drone*. Model masalah yang digunakan merupakan adaptasi dari model PLTSPHD (Arishi et al.

2022). Kendala-kendala yang memengaruhi pengiriman barang pada tahap *last mile* dengan sistem *truck-drone* melibatkan keterbatasan *drone* dan batasan waktu pelayanan (*time windows*) untuk setiap pelanggan.

Pembentukan rute dilakukan melalui dua tahap, yaitu tahap *clustering* dan *routing*. Pada tahap pertama, menerapkan *mean shift clustering* untuk mengelompokkan lokasi-lokasi pelanggan dan menentukan *centroid* atau pusat *cluster* yang akan dijadikan sebagai lokasi parkir *truck*. Lokasi parkir ini menjadi tempat peluncuran *drone* untuk melakukan pengiriman akhir ke lokasi pelanggan. Dalam tahap ini, terdapat dua batasan yang harus diperhatikan, yaitu jangkauan penerbangan *drone*, dan jumlah lokasi pelanggan dalam satu *cluster* tidak boleh melebihi jumlah *drone* yang tersedia.

Setelah mendapatkan hasil *cluster* dan pusat *cluster* dari tahap *clustering*, proses dilanjutkan ke tahap *routing*. Tahap ini menggunakan algoritma genetika dengan tujuan untuk membentuk rute perjalanan *truck* ke setiap lokasi parkir yang dihasilkan dari tahap *clustering*, dengan memperhatikan batasan waktu (*time windows*). Masalah pengiriman barang pada tahap *last mile* menggunakan sistem *truck-drone* dapat dimodelkan dalam bentuk PLTSPHD dengan memperhatikan batasan waktu.

Masalah *parking location traveling salesman problem* (PLTSPHD) bisa diselesaikan dengan merepresentasikan graf tidak berarah $S(U, A)$, dengan $U = U_0 \cup U$ merupakan himpunan simpul yang merepresentasikan pelanggan-pelanggan yang akan dilayani. U_0 adalah depot dan $U = \{1, 2, \dots, n\}$ merupakan himpunan semua titik pelanggan. $A = \{A_t, A_d\}$ adalah busur *truck* dan *drone* pada graf yang menghubungkan depot dengan pelanggan.

Pada masalah pengiriman barang pada tahap *last mile* menggunakan dua kendaraan yaitu satu *truck* dan beberapa *drone*. dimana *truck* akan membawa semua barang dan armada d *drone*. Kemudian berangkat dari depot menuju ke setiap lokasi parkir. Dalam hal ini lokasi parkir merupakan pusat-pusat *cluster* yang dihasilkan dari fase *clustering*. Himpunan *cluster* dinotasikan dengan $K = \{1, 2, \dots, p\}$. Misalkan terdapat p *cluster* maka himpunan lokasi parkir dinotasikan dengan $Centroid = \{cent_1, cent_2, \dots, cent_p\}$. Misalkan $k, l \in Centroid$, jarak antara lokasi parkir k dengan lokasi parkir l dinotasikan dengan $dist_{kl}$.

Setelah *truck* sampai di lokasi parkir, *drone* akan melakukan pengiriman ke lokasi pelanggan. Misalkan $k \in K$ dan $i \in U$, jarak antara lokasi parkir dengan lokasi pelanggan ke- i dalam *cluster* k dinotasikan dengan d_{0i}^k . Himpunan *drone* dinotasikan dengan $Drone = \{1, 2, \dots, d\}$. Untuk setiap $m \in Drone$ dan lintasan yang menghubungkan lokasi parkir k dengan pelanggan i , dimana $i, k \neq 0$, didefinisikan variable keputusan y_{0i}^{km} sebagai berikut :

$$y_{oi}^{km} = \begin{cases} 1, & \text{drone ke } m \text{ berjalan dari centroid } k \text{ ke pelanggan } i \\ 0, & \text{Lainnya} \end{cases} \quad (5)$$

Selain itu, untuk *truck* dan jalur yang menghubungkan lokasi parkir k dengan lokasi parkir l , didefinisikan variabel keputusan x_{kl} sebagai berikut:

$$x_{kl} = \begin{cases} 1, & \text{Jika truk berjalan dari cluster } l \text{ ke cluster } k \\ 0, & \text{Lainnya} \end{cases} \quad (6)$$

Tujuan dari penelitian ini adalah menyelesaikan masalah PLTSPHD untuk menemukan rute pengiriman barang yang meminimalkan total biaya pengiriman, maka fungsi objektif yang digunakan adalah sebagai berikut.

$$\text{Min } z = Y + \text{cost_dr} \left(\sum_{k=1}^p \sum_{m=1}^d y_{oi}^{km} \right) + \text{cost_tr} \sum_{k=1}^p \sum_{l=1, k \neq l}^p \text{dist}_{kl} x_{kl} \quad (8)$$

dengan Y sebagai berikut.

$$Y = \text{fixcost_tr} + \text{fixcos_dr} \cdot d + \text{parkcost} \cdot p \quad (9)$$

Fungsi objektif (7) merepresentasikan biaya pengiriman barang pada tahap *last mile* menggunakan sistem *truck-drone*. Biaya tetap *truck* (fixcost_tr) dan biaya tetap *drone* (fixcost_dr) adalah biaya tetap layanan pengiriman dan besarnya tidak tergantung pada seberapa jauh atau dekat lokasi pelanggan. Biaya ini meliputi segala biaya *operational* pengiriman barang seperti biaya pemeliharaan dan biaya tunjangan supir. Sedangkan biaya perjalanan *truck* (cost_tr) adalah biaya yang dikenakan berdasarkan jarak. Biaya perjalanan *truck* meliputi biaya bahan bakar yaitu bensin *truck*. Biaya perjalanan *drone* (cost_dr) merupakan biaya pengisian baterai, biaya perjalanan *drone* dihitung konstan berdasarkan jarak perjalanan maksimal sejauh 4 km. Meskipun sebenarnya jarak tempuh mungkin lebih pendek namun biaya yang dikenakan tetap setara dengan perjalanan sejauh 4 km. Biaya ini meliputi biaya pergantian baterai (*swap battery*). Biaya parkir (parkcost) adalah biaya parkir.

Berikut adalah kendala yang diperlukan pada masalah PLTSPHD.

1. Menyatakan *truck* berangkat dari depot

$$\sum_{k=1}^p x_{0k} = 1 \quad (10)$$

2. Menyatakan *truck* kembali ke depot

$$\sum_{k=1}^p x_{k0} = 1 \quad (11)$$

3. Memastikan terdapat perjalanan *truck* maksimal satu kali dari satu *cluster* k ke *cluster* l .

$$\sum_{k=0, k \neq l}^p x_{kl} \leq 1 \quad l \in \{1, 2, \dots, p\} \quad (12)$$

4. *Conservation flow*

$$\sum_{k=0, k \neq l}^p x_{kl} - \sum_{k=0, k \neq l}^p x_{lk} = 0 \quad l \in \{0, 1, 2, \dots, p\} \quad (13)$$

5. Memastikan tidak ada loop dalam rute *truck*

$$\sum_{k=1}^p \sum_{l=1, k \neq l}^p x_{kl} \leq p - 1 \quad (14)$$

6. Memastikan *drone* tidak melayani pelanggan lebih dari satu kali

$$\sum_{i=1}^n y_{0i}^{km} \leq 1 \quad \begin{array}{l} k \in \{1, 2, \dots, p\}; \\ m \in \{1, 2, \dots, d\} \end{array} \quad (15)$$

7. Memastikan *drone* kembali ke pusat *cluster* (lokasi parkir)

$$\sum_{m=1}^d \sum_{i=1}^n y_{i0}^{km} \leq d \quad k \in \{1, 2, \dots, p\} \quad (16)$$

8. Menyatakan jumlah pelanggan pada setiap *cluster* tidak boleh melebihi jumlah *drone* yang tersedia

$$\sum_{m=1}^d \sum_{i=1}^n y_{0i}^{km} \leq d \quad k \in \{1, 2, \dots, p\} \quad (17)$$

9. Menyatakan radius jarak dari pusat *cluster* (*centroid*) ke lokasi pelanggan tidak lebih maksimum penerbangan *drone*.

$$\sum_{i=1}^n d_{0i}^k y_{oi}^{km} \leq R \quad \begin{matrix} k \in \{1,2, \dots, p\}; \\ m \in \{1,2, \dots, d\} \end{matrix} \quad (18)$$

10. Inisialisasi waktu mulai rute di depot

$$w_0 = e_0 = 0 \quad (19)$$

11. Memastikan rute dilakukan dalam *time windows*

$$e_0 \leq p_k \leq l_0 \quad k \in \{1,2, \dots, p+1\} \quad (20)$$

12. Memastikan bahwa *time windows* di *centroid* (lokasi parkir) k kurang dari *time windows* pada *centroid* (lokasi parkir) l

$$\begin{aligned} w_k + x_{kl} \left(t_{kl} + pt_time + pd_time \left(\sum_{m=1}^d \sum_{i=1}^n y_{oi}^{km} \right) \right) & \leq p_l + l_0(1 - x_{kl}) \\ k \in \{1,2, \dots, p\}; & \\ l \in \{1,2, \dots, p\}; & \\ k \neq l & \end{aligned} \quad (21)$$

Data Penelitian

Data penelitian yang diperlukan meliputi informasi lokasi depot, lokasi pelanggan, armada pengiriman yang tersedia, jarak antar lokasi-lokasi, informasi waktu dan kecepatan pengiriman.

1. Depot

Depot dalam penelitian ini merupakan depot terakhir sebelum barang dikirimkan ke lokasi pelanggan. Fasilitas ini menjadi titik awal dan titik akhir dalam rangkaian pengiriman. Lokasi depot pengiriman pada penelitian ini berada di Jl. K.S. Tabun, RT.2/RW.4, Petamburan, Kecamatan Tanah Abang, Kota Jakarta Pusat, Daerah Khusus Ibukota Jakarta 11410. Dengan titik koordinat (-6.194515855159909, 106.80531792027882).

2. Armada Pengiriman

Pada penelitian ini, digunakan dua jenis kendaraan, yaitu *truck* dan *drone*, untuk melaksanakan pengiriman *last mile delivery*. *Truck* yang digunakan berjumlah

satu. *Drone* yang digunakan berjumlah 15 dengan setiap *drone* homogen dan identik. Berikut adalah beberapa spesifikasi untuk *drone* wings:

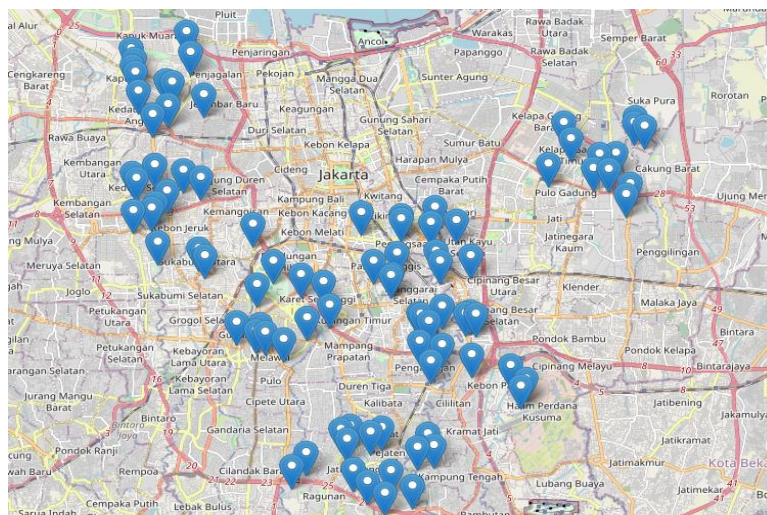
- Panjang *drone* 1,3 meter, panjang sayap 1 meter, dan berat sekitar 5,2 kg tanpa paket.
- Jarak maksimum yang dapat ditempuh oleh *drone* wings dalam satu misi pengiriman adalah 4 km.
- Kecepatan rata – rata *drone* wings dalam melakukan pengiriman adalah 104,4 km/jam atau sekitar 0,57 menit/km

3. Waktu

Data waktu yang diperlukan yaitu jam operasional pengiriman, waktu tempuh *truck*, waktu tempuh *drone*, dan waktu layanan (*service time*).

4. Lokasi Pelanggan

Data lokasi pelanggan diperoleh melalui penggunaan alat bantu *Google Maps*, suatu platform yang menyediakan informasi mengenai titik koordinat geografis berupa *latitude* dan *longitude*. Dengan memanfaatkan layanan ini, dapat memperoleh data yang akurat dan terpercaya untuk setiap lokasi yang dipilih. Lokasi pelanggan sebanyak 90 pelanggan. Lokasi pelanggan berupa rumah atau tempat yang menjadi tujuan pengiriman paket. Lokasi pelanggan tersebar di wilayah jabodetabek. Untuk setiap lokasi pelanggan diasumsikan bahwa hanya memiliki satu permintaan atau satu paket.



Gambar 3 Persebaran pelanggan pada peta

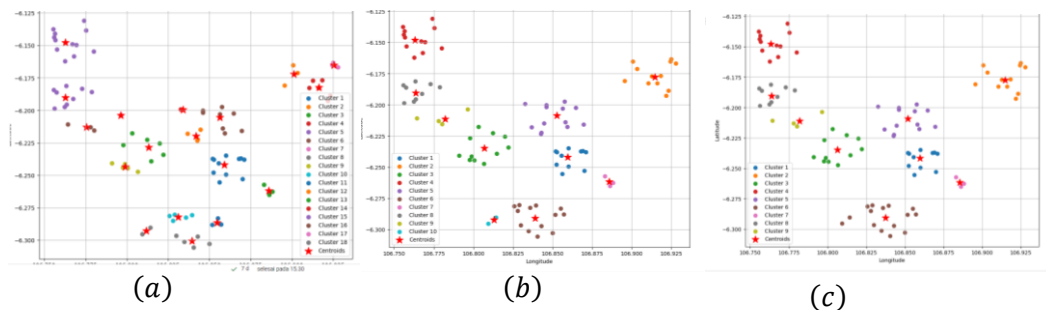
5. Biaya

Berikut adalah rincian biaya yang digunakan:

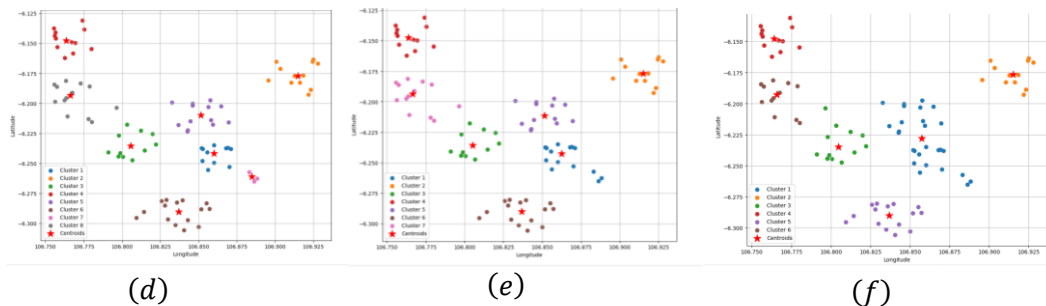
- Biaya tetap *truck* ($fixcost_{tr}$) = Rp137.000, - /*truck* (Mulyati dkk., 2014)
- Biaya tetap *drone* ($fixcost_{dr}$) = Rp154.000, - /*drone* (Ddsprtn, 2023; Singh, 2023)
- Biaya perjalanan *truck* ($cost_{tr}$) = Rp1.700, - /km (CNBC Indonesia, 2023; TruMecs, 2023)
- Biaya perjalanan *drone* ($cost_{dr}$) = Rp4.800, - /pelanggan (Sudbury & Hutchinson, 2016)
- Biaya parkir *truck* ($parkcost$) = Rp 7.000, - (Radityasani & Maulana, 2023)

Penentuan Parameter *Mean Shift Clustering*

Penentuan parameter *bandwidth* pada algoritma *mean shift clustering* dalam *Parking Location Traveling Salesman Problem with Homogeneous Drone* (PLTSPHD) memegang peran penting untuk mengoptimalkan hasil klusterisasi. Proses ini dilakukan secara subjektif dengan mencoba nilai *bandwidth* dari 0.5 hingga 1, sesuai dengan karakteristik data yang memiliki jarak relatif kecil antar titik. Evaluasi hasil klusterisasi dilakukan dengan mempertimbangkan batasan jumlah *cluster* seminimal mungkin untuk meminimalkan biaya transportasi pengiriman dan tidak melanggar batasan *cluster* yang diberikan.



Gambar 4 Hasil *Mean Shift Clustering* untuk *bandwidth* yang berbeda. (a) *bandwidth* = 0,5, (b) *bandwidth* = 0,6, (c) *bandwidth* = 0,7



Gambar 5 Hasil *Mean Shift Clustering* untuk *Bandwidth* yang berbeda. (d) *bandwidth* = 0,8, (e) *bandwidth* = 0,9, (f) *bandwidth* = 1

Visualisasi hasil klasterisasi dengan berbagai nilai *bandwidth*, seperti 0.5, 0.6, 0.7, 0.8, 0.9, dan 1, memberikan gambaran yang jelas. Hasil uji menunjukkan variasi jumlah *cluster*, dengan nilai *bandwidth* 0.9 memberikan hasil optimal dengan jumlah *cluster* minimal tanpa melanggar batasan. Oleh karena itu, nilai *bandwidth* 0.9 dipilih sebagai parameter optimal untuk menjalankan *mean shift clustering* pada masalah PLTSPHD.

Penentuan Parameter Algoritma Genetika

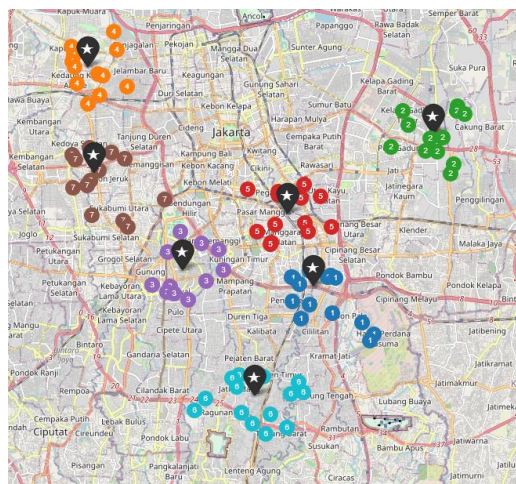
Berdasarkan rekomendasi dari Kusumadewi, (2005) parameter yang digunakan sebagai berikut:

- Probabilitas mutasi = 0,001
- Probabilitas *crossover* = 0,6
- Ukuran generasi = 100

Ukuran populasi adalah sebanyak lokasi parkir yang dihasilkan dari tahap *clustering*. Ukuran populasi ditentukan demikian karena terkait dari metode ANN (*All Nearest Neighbors*) yang digunakan untuk membangkitkan populasi awal. Dimana ANN memiliki aturan bahwa kromosom yang dibangkitkan harus diawali dari lokasi parkir yang berbeda (kromosom-*i* dimulai dari lokasi parkir ke-*i*).

Hasil Program Mean Shift Clustering

Dalam penelitian ini, menggunakan *Mean Shift clustering* untuk mengelompokkan dataset yang terdiri dari 90 lokasi pelanggan. Proses *clustering* diimplementasikan melalui program dengan bahasa *python* yang dijalankan pada *Google Collab* dengan menggunakan nilai *bandwidth* sebesar 0,9. Hasil dari proses *clustering* ini dapat dilihat melalui ilustrasi gambar di bawah ini.



Gambar 6 Mean Shift Clustering

Hasil dari **Gambar 6** menunjukkan terbentuknya 7 *cluster* (warna yang berbeda

menunjukkan *cluster* yang berbeda) dan masing-masing *cluster* memiliki *centroid* (ditunjukkan oleh icon berbintang warna hitam) yang akan dijadikan sebagai lokasi parkir *truck*.

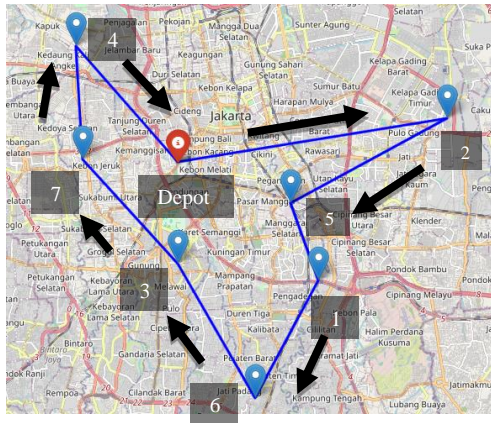
Hasil Program Algoritma Genetika

Setelah melakukan proses *clustering* dan didapatkan *centroid-centroid*, selanjutnya melakukan proses *routing* untuk mencari rute optimal pengiriman barang menggunakan kendaraan *truck* dengan metode algoritma genetika. Proses *routing* diimplementasikan melalui program dengan bahasa *Python* yang dijalankan pada *Google Collab*. Sebelum itu, dibangkitkan populasi awal terlebih dahulu menggunakan ANN (*All Nearest Neighbors*). Berikut populasi awal ANN yang diperoleh dari program.

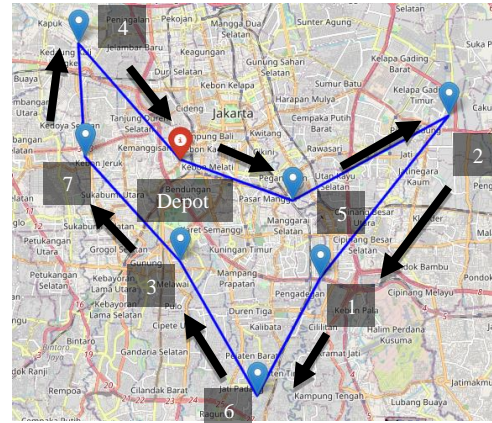
Tabel 1 Populasi Awal ANN

Kromosom	Rute	Total jarak	Waktu perjalanan
1	0 – 1 – 5 – 3 – 7 – 4 – 2 – 6 – 0	72,76 km	08.00 – 16.02 WIB
2	0 – 2 – 5 – 1 – 6 – 3 – 7 – 4 – 0	55,42 km	08.00 – 15.27 WIB
3	0 – 3 – 5 – 1 – 6 – 7 – 4 – 2 – 0	67,76 km	08.00 – 15.52 WIB
4	0 – 4 – 7 – 3 – 5 – 1 – 6 – 2 – 0	61,49 km	08.00 - 15.39 WIB
5	0 – 5 – 1 – 6 – 3 – 7 – 4 – 2 – 0	62,92 km	08.00 - 15.42 WIB
6	0 – 6 – 1 – 5 – 3 – 7 – 4 – 2 – 0	67,47 km	08.00 -15.51 WIB
7	0 – 7 – 4 – 3 – 5 – 1 – 6 – 2 – 0	63,30 km	08.00 - 15.43 WIB

Dari **Tabel 1** terdapat 7 kromosom, yang masing-masing merepresentasikan solusi potensial dalam pencarian rute optimal. Setiap solusi dalam tabel tersebut mematuhi batasan waktu, sehingga dapat dianggap sebagai rute yang *feasible*. Kromosom kedua, yang menggambarkan rute 0 – 2 – 5 – 1 – 6 – 3 – 7 – 4 – 0, menunjukkan jarak terpendek dengan nilai 55,42 km. Meskipun demikian, tetap mencari solusi yang mungkin lebih optimal melalui penerapan algoritma genetika. Proses algoritma genetika dalam program dengan bahasa *python* dijalankan sebanyak 100 generasi. Setelah 100 generasi didapatkan solusi rute optimal yaitu 0 – 5 – 2 – 1 – 6 – 3 – 7 – 4 – 0 dengan nilai *fitness* 0,018440002685214583 dan total jarak 54,22 km. Solusi ini lebih baik dibandingkan solusi yang diperoleh melalui metode ANN namun tidak terlalu signifikan. Ilustrasi gambar rute optimal dengan ANN 0 – 2 – 5 – 1 – 6 – 3 – 7 – 4 – 0 dan dengan algoritma genetika yaitu 0 – 5 – 2 – 1 – 6 – 3 – 7 – 4 – 0 dapat dilihat di bawah ini.



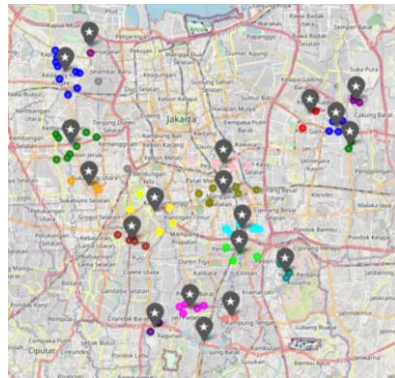
Gambar 7 Ilustrasi rute optimal awal ANN



Gambar 8 Ilustrasi rute optimal Algoritma Genetika

Hasil dan Diskusi

Pada tahap ini dilakukan analisis hasil perbandingan efisiensi biaya pada rute optimal yang dihasilkan menggunakan algoritma genetika dan *mean shift clustering* dengan algoritma genetika dan *clustering* dengan metode *intuitif*.




Gambar 9 Solusi *clustering* dengan metode *intuitif*



Gambar 10 *Mean Shift Clustering*


Dalam membandingkan hasil dari metode *mean shift clustering* dengan *clustering* dengan metode *intuitif* kriteria dalam aspek jumlah *cluster* diterapkan untuk menilai efektivitas keduanya dalam konteks permasalahan PLTSPHD. Berdasarkan hasil visualisasi pada **Gambar 9** dan **Gambar 10**, terlihat bahwa terdapat perbedaan signifikan dalam jumlah *cluster* yang dihasilkan oleh keduanya. *Mean shift clustering* menghasilkan 7 *cluster*, sementara solusi *clustering* dengan metode *intuitif* menghasilkan 19 *cluster* dan 2 *outlier*.



Gambar 11 Grafik Jumlah *Cluster*


Pada data ini, penggunaan *mean shift clustering* tampaknya lebih efisien dalam membentuk kelompok data. Hal ini ditunjukkan dari penurunan jumlah *cluster* yang dihasilkan oleh metode *mean shift clustering* sebesar 63% dibandingkan metode *intuitif*. Jumlah *cluster* yang lebih sedikit yang dihasilkan dapat dianggap menguntungkan dalam konteks permasalahan PLTSPHD yang menekankan minimalisasi biaya transportasi. Sebaliknya, *clustering* dengan metode *intuitif* yang menghasilkan 19 *cluster* mungkin tidak seefisien dalam hal biaya. Namun dievaluasi lebih lanjut terkait efisiensi dari biaya pengiriman.

Melalui implementasi algoritma genetika menggunakan program dengan bahasa *python*, ditemukan solusi optimal untuk rute yang berasal dari lokasi parkir (*centroid*) hasil pengelompokan dengan *mean shift clustering*. Rutenya adalah 0 – 5 – 2 – 1 – 6 – 3 – 7 – 4 – 0, dengan total jarak tempuh sejauh 54,22 km dan waktu tempuh dari pukul 08.00 WIB hingga 15.25 WIB atau sekitar 442 menit. Menggunakan program yang sama, diperoleh rute optimal dari lokasi parkir (pusat *cluster*) hasil *clustering* dengan metode *intuitif* yaitu 0 – 7 – 16 – 19 – 18 – 17 – 8 – 9 – 10 – 11 – 13 – 14 – 12 – 15 – 6 – 5 – 4 – 2 – 1 – 3 – 0 dengan total jarak tempuh sebesar 74,90 km dan waktu tempuh mulai dari pukul 08.00 WIB sampai 17.55 WIB atau sekitar 596 menit. Berikut grafik perbandingan setelah proses *routing* menggunakan algoritma genetika dari *clustering* dengan metode *intuitif* dan *mean shift clustering*.




Gambar 12 Grafik Total Biaya Pengiriman

Berdasarkan **Gambar 12** *mean shift clustering* menghasilkan biaya yang lebih efisien dibandingkan dengan metode *intuitif*. Hal ini ditunjukkan dari penurunan biaya *mean shift clustering* sebesar 3,51 %.



Gambar 13 Grafik Total Jarak Pengiriman



Gambar 14 Grafik Waktu Tempuh Pengiriman

Selain itu, hasil juga menunjukkan bahwa *mean shift clustering* dapat mengurangi total jarak sebesar 27,93% dan waktu tempuh 25,83 %. dibandingkan metode *intuitif*.

Kesimpulan

Permasalahan pengiriman barang dengan sistem *truck-drone* pada tahap *last mile* dapat dimodelkan menjadi *Parking Location Traveling Salesman Problem with Homogenous Drone* (PLTSPHD) dengan memperhatikan kendala jangkauan maksimum terbang *drone* dan jam kerja pengiriman harian. Implementasi metode *mean shift clustering* pada model PLTSPHD menghasilkan identifikasi *cluster* yang optimal untuk pelanggan. Hasil eksperimen menunjukkan keefisienan metode ini dalam membentuk kelompok data dan menemukan lokasi parkir optimal. Dibandingkan dengan metode *intuitif*, *mean shift clustering* mampu

menurunkan jumlah *cluster* sebesar 63%. Langkah selanjutnya menggunakan algoritma genetika pada hasil *clustering* memberikan rute yang lebih efisien. Hasil analisis menunjukkan penurunan biaya sebesar 3,51%, serta pengurangan total jarak dan waktu tempuh masing-masing sebesar 27,93% dan 25,83%. Kombinasi *mean shift clustering* dan algoritma genetika membuktikan keunggulannya dalam mengoptimalkan rute pada konteks PLTSPHD. Keseluruhan, penelitian ini memberikan kontribusi positif dalam meningkatkan efisiensi pengiriman barang dengan memanfaatkan pendekatan *clustering* dan algoritma genetika.

Daftar Referensi

- Abdulkarim & Alshammar. (2015). Comparison of Algorithms for Solving Traveling Salesman Problem. *International Journal of Engineering and Advanced Technology (IJEAT)*, 4(6), 76. ISSN: 2249-8958 (Online).
- Arishi, A., Krishnan, K., & Arishi, M. (2022). Machine learning approach for *truck-drones* based last-mile *delivery* in the era of industry 4.0. *Engineering Applications of Artificial Intelligence*, 116. <https://doi.org/10.1016/j.engappai.2022.105439>
- Carreira-Perpinán M A. (2015). A review of mean-shift algorithms for *clustering*. arXiv (Preprint arXiv:1503.00687)
- CNBC Indonesia. (2023). Daftar Harga BBM Terbaru di Seluruh SPBU RI 14 Desember 2023. CNBC Indonesia. <https://www.cnbcindonesia.com/news/20231214081505-4-497182/daftar-harga-bbm-terbaru-di-seluruh-spbu-ri-14-desember-2023>
- Ddsprtn. (2023). Ternyata Segini Besar Gaji *Drone* Pilot di Indonesia. Kompasiana. <https://www.kompasiana.com/ddsprtn/650ecc7308a8b515da2a13b2/ternyata-segini-besar-gaji-drone-pilot-di-indonesi>
- Dolan, S. (2021). The challenges of *last mile delivery* logistics and the tech solutions cutting costs in the final mile. *Businessinder*. <https://www.businessinder.com/last-mile-delivery-shipping-explained?r=US&IR=T>
- Eskandaripour, H., & Boldsai Khan, E. (2023). Last-Mile *Drone* Delivery: Past, Present, and Future. 7(2), 77. <https://doi.org/10.3390/drones7020077>
- Hamdy Taha (1996). Riset Operasi. Jilid satu. Jakarta: Binarupa Aksara.
- Kominfo. (2023). Siaran Pers No. 28/HM/KOMINFO/03/2023: Tentang Kembangkan Ekonomi Digital, Indonesia Butuh Talenta Digital Berkualitas. Kementerian Komunikasi dan Informatika Republik Indonesia.
- Kusumadewi, Sri (2005). Penyelesaian Masalah Optimasi dengan Teknik-teknik Heuristik.

Graha Ilmu.

- Murray, C. C., & Chu, A. G. (2015). Parallel *Drone Scheduling Traveling Salesman Problem* (PDSTSP) and Flying Sidekick *Traveling Salesman Problem* (FSTSP). *Transportation Research Part C: Emerging Technologies*, 54, 86-109.
- Satriyanto, E. (2009). *Algoritma Genetika*. Jakarta: Duta Ilmu Press.
- Statista. (2023). Number of users of *e-commerce* in Indonesia from 2018 to 2027. Statista Media Insight. <https://www.statista.com/forecasts/251635/e-commerce-users-in-indonesia>
- Savuran, H., Karakaya. (2016). M. Efficient route planning for an unmanned air vehicle deployed on a moving carrier. *Soft Comput* 20, 2905–2920.
<https://doi.org/10.1007/s00500-015-1970-4>
- Sudbury, A. W., & Hutchinson, E. B. (2016). A COST ANALYSIS OF AMAZON PRIME AIR (DRONE DELIVERY). Dalam |JOURNAL FOR ECONOMIC EDUCATORS (Vol. 16, Nomor 1).
<https://libjournals.mtsu.edu/index.php/jfee/article/download/1512/1090/4144>
- Yulianto, E., & Setiawan, A. (2018). Optimasi Rute Sales Coverage Menggunakan Algoritma Cheapest Insertion Heuristic dan Layanan Google Maps API. Universitas Langlangbuana.

